Predicción Multiclase de la Deserción Estudiantil mediante Máquinas de Soporte Vectorial: Análisis Comparativo de Métodos de Normalización

Sara López Chavarro, Nicolás Figueroa Salgado, Arnold Santiago Torres Anzola
Ciencia de Datos

***Abstract*—La identificación de patrones asociados con la deserción estudiantil constituye un problema relevante para las instituciones de educación superior. Este trabajo compara máquinas de soporte vectorial (SVM) para clasificar tres estados académicos: Graduado, En curso y Desertor. Se utiliza un conjunto de $11\,500$ registros y 21 variables predictoras, construido mediante simulación con fines académicos y tomando como referencia el contexto de SPADIES 3.0. Se evalúan los kernels Radial Basis Function (RBF) y polinómico de grado tres (Poly-3), ocho configuraciones de preprocesamiento y un clasificador Dummy como línea base. El protocolo comprende 50 repeticiones de Monte Carlo Repeated Holdout y una evaluación final sobre $2\,300$ registros reservados. Poly-3 con Power Transformer obtuvo el mayor F1 Macro en test (0.8923), mientras que RBF con Standard Scaler alcanzó el mayor Recall para Desertor (0.9211). Adicionalmente, SHAP, LIME y PDP permitieron examinar los patrones globales y locales aprendidos por ambos clasificadores.**

***Index Terms*—Deserción estudiantil, aprendizaje automático, máquinas de soporte vectorial, SVM, normalización, clasificación multiclase, interpretabilidad.**

I. Introducción

La deserción estudiantil representa un desafío para las instituciones de educación superior por sus implicaciones académicas, económicas y sociales. Su análisis requiere considerar características individuales, académicas y socioeconómicas. En este contexto, el aprendizaje automático permite explorar relaciones entre variables y construir modelos de clasificación de estados académicos.

Las máquinas de soporte vectorial (SVM) construyen fronteras de decisión a partir de los datos de entrenamiento y, mediante funciones kernel, pueden representar relaciones no lineales. Su desempeño depende, entre otros factores, de la escala de las variables, pues las distancias intervienen en la construcción del modelo.

Boteju et al. [1] estudiaron la aplicación de SVM a la predicción de deserción bajo diferentes métodos de normalización. Tomando ese trabajo como referente, esta investigación desarrolla un experimento inspirado en el contexto colombiano de SPADIES 3.0 [2]. Se comparan los kernels RBF y Poly-3, ocho configuraciones de preprocesamiento y un clasificador de referencia para tres estados académicos.

El objetivo es identificar las configuraciones con mejor F1 Macro y Recall para Desertor, además de examinar matrices de confusión, importancia de variables, explicaciones locales y diferencias descriptivas entre subgrupos.

Table I
Distribución de las clases.

Clase	Registros	Porcentaje
En curso	5 137	44.67%
Desertor	3 863	33.59%
Graduado	2 500	21.74%
Total	11 500	100%

II. Materiales y métodos

A. Conjunto de datos

Se empleó un conjunto de $11\,500$ registros y 21 variables predictoras: 11 numéricas y 10 categóricas. Su estructura toma como referencia el contexto de caracterización académica y socioeconómica de SPADIES 3.0. El conjunto fue construido mediante simulación con fines académicos y autorización docente; no corresponde a registros reales ni a información oficial del sistema.

El archivo original contiene las 21 variables predictoras; la variable objetivo *estado_final* se genera durante el preprocesamiento. Por tanto, el conjunto preparado contiene 22 columnas. La distribución de las clases se presenta en la Tabla I.

Las etiquetas se construyeron mediante reglas que combinan características académicas y socioeconómicas. El puntaje de riesgo se definió como:

$$\begin{aligned} R = {} & 2.5I(P < 3.0) + 2.5I(M \geq 2) \\ & + I(ICFES < 40) + I(T = 1) \\ & + 0.5I(B = 0) + 0.5I(E \leq 2), \end{aligned} \tag{1}$$

donde P es el promedio, M las materias reprobadas, T la situación laboral, B el beneficio de beca y E el estrato. $I(\cdot)$ es una función indicadora. Se asignó Desertor cuando $R \geq 3.5$. Entre los registros restantes, se asignó Graduado cuando el semestre cursado alcanzó la duración nominal del nivel de formación y el promedio fue al menos 3.2; los demás se clasificaron como En curso. Las duraciones fueron cuatro semestres para técnico profesional, seis para tecnológico y diez para universitario.

B. Exploración y preprocesamiento

Se examinaron las distribuciones de las variables y sus relaciones mediante correlaciones de Pearson y Spearman. Las

Table II
F1 MACRO PROMEDIO Y DESVIACIÓN ESTÁNDAR EN MONTE CARLO.

Configuración	RBF	Poly-3
Standard Scaler	0.8808 ± 0.0072	0.8866 ± 0.0058
Power Transformer	0.8782 ± 0.0072	0.8897 ± 0.0059
Robust Scaler	0.8685 ± 0.0078	0.8744 ± 0.0067
Ordinal Encoder	0.8376 ± 0.0080	0.8532 ± 0.0071
Quantile Transformer	0.8328 ± 0.0071	0.8367 ± 0.0074
Min-Max Scaler	0.8296 ± 0.0081	0.8313 ± 0.0071
Max Absolute Scaler	0.8254 ± 0.0086	0.8348 ± 0.0074
No Normalization	0.4094 ± 0.0061	0.4977 ± 0.0107

características numéricas y categóricas se procesaron mediante transformaciones diferenciadas.

Se evaluaron ocho configuraciones: Standard Scaler, Min-Max Scaler, Robust Scaler, Quantile Transformer, Max Absolute Scaler, Power Transformer (Yeo-Johnson), No Normalization y Ordinal Encoder. Los primeros métodos transforman las escalas o distribuciones numéricas; No Normalization conserva la escala original y Ordinal Encoder constituye una alternativa de codificación categórica, no una normalización numérica.

C. Modelos y diseño experimental

Se implementaron dos SVM: RBF, basado en distancias entre observaciones, y Poly-3, con kernel polinómico de grado tres. Como línea base se incorporó DummyClassifier con estrategia *Most Frequent*, que predice siempre la clase mayoritaria.

Los transformadores y clasificadores se integraron mediante Pipeline, ajustando el preprocesamiento exclusivamente con los datos de entrenamiento de cada partición para evitar filtraciones de información.

Se realizó una división estratificada con semilla 42: 9 200 registros para desarrollo (80%) y 2 300 para prueba final (20%). La selección de configuraciones se efectuó en desarrollo mediante Monte Carlo Repeated Holdout, con 50 particiones aleatorias de entrenamiento y validación en proporción 80/20. Se seleccionó la configuración con mayor F1 Macro promedio para cada kernel y posteriormente se evaluó una sola vez sobre el test reservado.

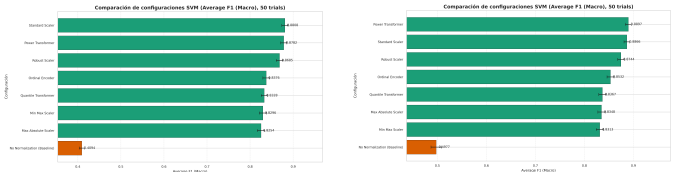
Se calcularon Accuracy, F1 Macro, F1 Weighted y Recall de Desertor. También se obtuvieron matrices de confusión, importancia por permutación, explicaciones mediante SHAP y LIME, gráficos PDP y una auditoría descriptiva del Recall de Desertor por subgrupos. Las particiones repetidas pueden compartir observaciones, por lo que no deben considerarse estadísticamente independientes.

III. RESULTADOS Y DISCUSIÓN

A. Resultados de Monte Carlo

La Tabla II presenta el F1 Macro promedio y su desviación estándar en las 50 repeticiones. Standard Scaler obtuvo el mejor resultado para RBF (0.8808), mientras que Power Transformer fue la mejor configuración para Poly-3 (0.8897).

La desviación estándar relativamente baja de las configuraciones superiores indica estabilidad entre las particiones



(a) SVM RBF (b) SVM Poly-3

Figure 1. Comparación del desempeño de las configuraciones de preprocesamiento.

Table III
RESULTADOS DE LOS MODELOS SOBRE EL TEST FINAL.

Modelo	Accuracy	F1-M	F1-W	Recall-D
SVM RBF	0.8891	0.8885	0.8890	0.9211
SVM Poly-3	0.8922	0.8923	0.8921	0.9082
Dummy	0.4465	0.2058	0.2757	0.0000

Table IV
PRECISIÓN, RECALL Y F1 POR CLASE EN EL TEST FINAL.

Modelo	Clase	Precisión	Recall	F1
RBF	Graduado	0.8561	0.9040	0.8794
RBF	En curso	0.9101	0.8578	0.8832
RBF	Desertor	0.8856	0.9211	0.9030
Poly-3	Graduado	0.8821	0.8980	0.8900
Poly-3	En curso	0.9001	0.8773	0.8886
Poly-3	Desertor	0.8886	0.9082	0.8983

realizadas, aunque no demuestra por sí sola generalización a datos reales ni ausencia de sobreajuste.

B. Comparación de configuraciones

La Figura 1 resume el desempeño de las configuraciones para ambos kernels. Las alternativas con mejores resultados difieren entre modelos, lo que evidencia la importancia de evaluar conjuntamente el transformador y la función kernel.

C. Evaluación sobre el test final

RBF utilizó Standard Scaler y Poly-3 Power Transformer. La Tabla III presenta los resultados sobre los 2 300 registros reservados.

Poly-3 obtuvo el mayor Accuracy (0.8922), F1 Macro (0.8923) y F1 Weighted (0.8921). RBF alcanzó el mayor Recall para Desertor (0.9211), frente a 0.9082 de Poly-3. Por tanto, el modelo con mejor desempeño global no necesariamente maximiza la identificación de una categoría específica.

La Tabla IV detalla las métricas por clase. Ambos modelos mantuvieron valores de F1 cercanos a 0.88 o superiores.

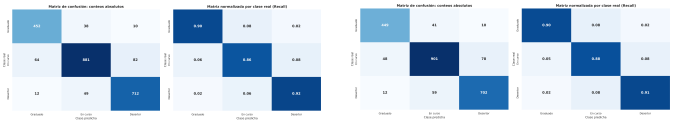
D. Comparación con el estudio de referencia

Boteju et al. [1] analizaron SVM con diferentes métodos de normalización utilizando 4 424 registros de UCI y reportaron un F1 de 0.778554 para su mejor configuración con One-Hot. La Tabla V resume las diferencias.

Esta comparación es contextual y no constituye una reproducción directa. Las diferencias entre conjuntos de datos, etiquetas y protocolos impiden atribuir la variación de las

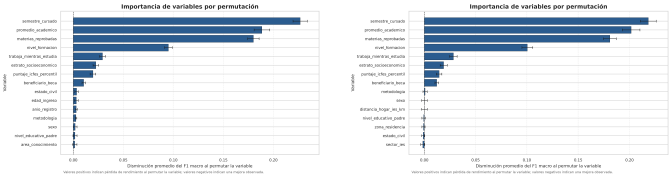
Table V
COMPARACIÓN METODOLÓGICA CON BOTEJU ET AL.

Aspecto	Boteju et al.	Este estudio
Registros	4 424	11 500
Datos	UCI	Simulados, ref. SPADIES
Kernel	Poly-3	RBF y Poly-3
Evaluación	Protocolo del estudio	50 part. y test final
Mejor resultado	F1: 0.7786	F1 Macro: 0.8923
Preprocesamiento	One-Hot	Power y Standard



(a) SVM RBF (b) SVM Poly-3

Figure 2. Matrices de confusión de los modelos SVM seleccionados.



(a) SVM RBF (b) SVM Poly-3

Figure 3. Importancia de variables por permutación.

métricas exclusivamente al preprocesamiento. Además, el F1 reportado en el trabajo de referencia no debe interpretarse como necesariamente equivalente al F1 Macro calculado en este estudio.

E. Matrices de confusión

RBF clasificó correctamente 452 registros de Graduado, 881 de En curso y 712 de Desertor. Poly-3 clasificó correctamente 449, 901 y 702 registros, respectivamente.

En RBF, 49 desertores fueron clasificados como En curso y 12 como Graduado. En Poly-3, 59 fueron clasificados como En curso y 12 como Graduado. Esto explica parcialmente el mayor Recall de Desertor de RBF. Dummy predijo todos los registros como En curso: aunque obtuvo Accuracy de 0.4465, su Recall para Desertor fue cero.

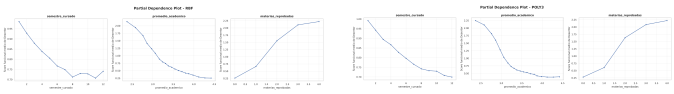
F. Importancia de variables por permutación

En ambos modelos destacaron semestre cursado, promedio académico, materias reprobadas y nivel de formación. Sus importancias promedio fueron 0.2268, 0.1885, 0.1800 y 0.0951 para RBF, y 0.2184, 0.2016, 0.1809 y 0.1005 para Poly-3.

La importancia por permutación mide la variación del rendimiento al alterar una característica y no representa causalidad. Los valores cercanos a cero o negativos pueden reflejar contribuciones marginales o variabilidad del procedimiento.

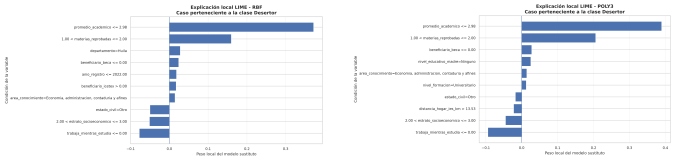
G. Interpretabilidad mediante PDP, LIME y SHAP

Se aplicaron técnicas de interpretabilidad global y local a los modelos finales. Los PDP examinan la respuesta promedio del clasificador ante variaciones de una variable; LIME aproxima



(a) SVM RBF (b) SVM Poly-3

Figure 4. Dependencia parcial de las variables académicas para ambos modelos.



(a) SVM RBF (b) SVM Poly-3

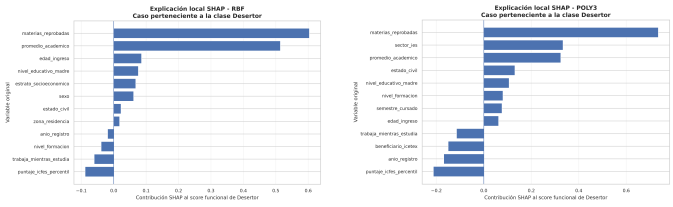
Figure 5. Explicaciones locales LIME para una instancia clasificada como Desertor.

localmente el comportamiento del modelo mediante un sustituto interpretable, y SHAP distribuye las contribuciones de las características a la salida explicada.

Dependencia parcial. En ambos modelos se observaron tendencias semejantes para `semestre_cursado`, `promedio_academico` y `materias_reprobadas`. La puntuación funcional asociada a Desertor disminuyó al aumentar el semestre cursado y el promedio académico, mientras que aumentó con el número de materias reprobadas. En particular, la reducción pronunciada alrededor de un promedio de 3.0 coincide con el umbral utilizado en la regla sintética de generación de etiquetas (`promedio_academico < 3.0`). Por tanto, este comportamiento debe interpretarse como una manifestación de los patrones incorporados durante la construcción del conjunto de datos, y no como un descubrimiento independiente sobre la deserción estudiantil. Los PDP describen la respuesta promedio de los clasificadores y no representan efectos causales ni probabilidades calibradas.

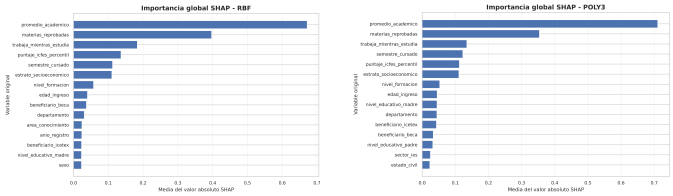
Explicaciones locales con LIME. Se examinó una instancia del conjunto de prueba clasificada como Desertor para comparar las explicaciones locales de ambos modelos. En el caso analizado, el promedio académico y las materias reprobadas presentaron las mayores contribuciones positivas hacia dicha clase. En Poly-3, la condición `promedio_academico <= 2.98` tuvo un peso aproximado de +0.39, seguida por `1.00 < materias_reprobadas <= 2.00`, con +0.21. En RBF, los pesos correspondientes fueron cercanos a +0.36 y +0.16. Los pesos negativos contribuyeron en sentido contrario a la explicación local. Estos valores corresponden a la aproximación local de LIME y no deben interpretarse como probabilidades.

Explicaciones SHAP locales. En las explicaciones locales, `materias_reprobadas` presentó la mayor contribución positiva para Poly-3, superior a +0.7, seguida por `sector_ies` y `promedio_academico`, con valores cercanos a +0.33 y +0.32. En RBF destacaron `materias_reprobadas` (+0.60) y `promedio_academico` (+0.51). Algunas variables, como `puntaje_icfes_percentil`, aportaron contribuciones



(a) SHAP local RBF (b) SHAP local Poly-3

Figure 6. Contribuciones SHAP locales para una instancia clasificada como Desertor.



(a) SHAP global RBF (b) SHAP global Poly-3

Figure 7. Importancia global de variables mediante SHAP.

negativas para el caso analizado.

Importancia global SHAP. En ambos modelos, `promedio_academico` ocupó el primer lugar, con valores medios absolutos superiores a 0.7 para Poly-3 y cercanos a 0.67 para RBF. Le siguió `materias_reprobadas`, con valores aproximados de 0.35 y 0.39, respectivamente. También destacaron `trabaja_mientras_estudia`, `semestre_cursado` y `puntaje_icfes_percentil`, aunque con contribuciones menores.

La diferencia entre el ranking SHAP y la importancia por permutación no constituye una contradicción: SHAP resume la magnitud de las contribuciones a las salidas del modelo, mientras que la permutación mide la pérdida de rendimiento al alterar una variable. En conjunto, las técnicas coinciden en destacar el promedio académico y las materias reprobadas. Las puntuaciones SHAP y PDP corresponden a la salida funcional asociada a Desertor; no deben interpretarse como probabilidades calibradas. Asimismo, las explicaciones describen patrones aprendidos sobre datos simulados y no permiten establecer relaciones causales.

H. Auditoría descriptiva por subgrupos

Se examinó el Recall de Desertor según sexo, zona, sector institucional y metodología. En RBF fue 0.9310 para hombres, 0.9129 para mujeres, 0.9306 para zona rural y 0.9189 para urbana. En Poly-3 fue 0.9023, 0.9129, 0.9375 y 0.9014, respectivamente.

Por metodología, RBF obtuvo 0.9670 en modalidad virtual, 0.9165 en presencial y 0.9084 en distancia tradicional. Poly-3 alcanzó 0.9231, 0.9074 y 0.9008. Estas diferencias son descriptivas y no constituyen una evaluación integral de equidad algorítmica.

I. Aplicación de consulta

Se desarrolló una aplicación interactiva con Streamlit que permite ingresar características de un registro y consultar las predicciones de ambos modelos, junto con una comparación de resultados. La aplicación utiliza los pipelines previamente entrenados, sin ajustar nuevamente los clasificadores durante la consulta. Su ejecución local se realiza mediante `streamlit run app.py`. Como etapa posterior, se contempla su despliegue en Streamlit Community Cloud, con el propósito de facilitar el acceso mediante un enlace web. El código y los recursos del proyecto están disponibles en GitHub [3].

IV. Limitaciones

Los resultados están condicionados por las reglas empleadas para generar las etiquetas y por el conjunto simulado. Por ello, no demuestran capacidad predictiva sobre estudiantes reales. Monte Carlo permite examinar variación entre particiones, pero estas pueden compartir observaciones. Se utilizó un único conjunto generado con una semilla y no se realizó validación cruzada anidada.

Tampoco se efectuó una búsqueda exhaustiva de hiperparámetros: se utilizaron los valores predeterminados de C y γ. La importancia por permutación y la auditoría por subgrupos, calculadas sobre el mismo test, deben considerarse exploratorias. Las técnicas SHAP y LIME también presentan limitaciones asociadas con la representación numérica de variables categóricas durante las perturbaciones. En consecuencia, las explicaciones deben interpretarse como aproximaciones descriptivas del comportamiento de los modelos, no como relaciones causales ni como fundamento suficiente para decisiones institucionales sobre estudiantes reales.

V. Conclusiones

El experimento comparó dos kernels SVM bajo ocho configuraciones de preprocesamiento. Monte Carlo identificó Standard Scaler como la mejor configuración para RBF y Power Transformer para Poly-3. En el test final, Poly-3 obtuvo el mayor F1 Macro (0.8923), mientras que RBF alcanzó el mayor Recall para Desertor (0.9211). La elección depende, por tanto, de la métrica priorizada. Ambos modelos superaron al DummyClassifier, cuyo Recall para Desertor fue cero.

La importancia por permutación destacó semestre cursado, promedio académico, materias reprobadas y nivel de formación. Las explicaciones SHAP, LIME y PDP complementaron estos resultados al mostrar la relevancia del promedio académico y las asignaturas reprobadas en las salidas de ambos clasificadores. La coincidencia de estos patrones aporta consistencia descriptiva dentro del escenario simulado, sin demostrar relaciones causales ni validez sobre población real.

Como trabajo futuro se propone evaluar datos reales debidamente autorizados, incorporar validaciones externas y realizar búsqueda sistemática de hiperparámetros para examinar la estabilidad de los modelos en otros contextos.

Declaración de uso de herramientas de IA

Se utilizó ChatGPT como apoyo para la revisión de redacción, organización del documento y asistencia durante el desarrollo y revisión del código. Las decisiones metodológicas, la ejecución de los experimentos y la interpretación de los resultados corresponden al equipo autor.

REFERENCES

[1] G. Boteju, L. Tang, y M. Scott Brown, "Support Vector Machine for Predicting Student Dropout Under Different Normalization Methods," en *IEEE International Conference on Big Data (Big Data)*, 2024, pp. 8633–8638.

[2] Ministerio de Educación Nacional de Colombia, *SPADIES 3.0: Cambio Metodológico*, MEN, 2024. [En línea]. Disponible en: https://www.mineducacion.gov.co/sistemasdeinformacion/1783/articles-415244_cambio_metodologico_spadies_3.pdf.

[3] S. López Chavarro, N. Figueroa Salgado y A. S. Torres Anzola, "Proyecto Machine Learning II: Predicción de deserción estudiantil mediante SVM," GitHub, 2026. [En línea]. Disponible en: https://github.com/eljarcor98/Proyecto_Machine_Learning_II/tree/main.