

Caracterización del Dataset, Formulación de la Variable Objetivo e Impacto de Métodos de Normalización en Máquinas de Vectores de Soporte (SVM)

Arnold Santiago Torres
Proyecto de Machine Learning II
Universidad 2026-II

28 de septiembre de 2026

Resumen

El presente documento reúne de forma sistemática la caracterización técnica del conjunto de datos `estudiantes_sinteticos_11500.csv`, la formulación matemática de la variable objetivo binaria de deserción, las estadísticas descriptivas pre-normalización, la justificación de hiperparámetros del estimador SVM (SVC) y la fundamentación teórica de seis métodos de escalamiento evaluados en conformidad con la literatura científica reciente (IEEE 2024). El análisis demuestra la necesidad estricta de la normalización de características para evitar el sesgo de la norma euclidiana en el kernel RBF.

1. Información General del Dataset

El conjunto de datos compilado para el modelo de predicción temprana de deserción presenta la siguiente estructura técnica:

- **Nombre del archivo:** `estudiantes_sinteticos_11500.csv`
- **Total de registros:** 11,500 observaciones de estudiantes.
- **Total de variables:** 22 (21 características predictoras y 1 variable objetivo).
- **Valores nulos / faltantes:** 0 (0.0 %).
- **Distribución de la Variable Objetivo (desercion):**
 - Clase 0 (No deserción / Permanencia): 7,637 estudiantes (66.41 %).
 - Clase 1 (Deserción estudiantil): 3,863 estudiantes (33.59 %).

2. Diccionario Completo de Variables

2.1. Variables Socio-Demográficas y Geográficas

2.2. Variables Académicas

2.3. Variables Socioeconómicas, Familiares y Financieras

3. Criterio y Formulación de la Variable Objetivo (desercion)

La variable respuesta $desercion_i \in \{0, 1\}$ se definió mediante un índice de riesgo continuo ponderado $R_i \in [0, 7, 5]$:

Variable	Tipo de Dato	Tipo Rango	Rango Original	Descripción
edad_ingreso	Numérica (Entero)	Discreto	[15 – 32] años	Edad del estudiante al ingresar.
sexo	Categórica	Nominal	'Hombre', 'Mujer'	Género reportado por el estudiante.
estado_civil	Categórica	Nominal	4 categorías	Estado civil en matrícula.
zona_residencia	Categórica	Nominal	'Urbana', 'Rural'	Zona de procedencia de vivienda.
departamento	Categórica	Nominal	27 dptos. Colombia	Departamento de origen.
distancia_hogar_ies_km	Numérica (Continuo)	Continuo	[0,22 – 250,00] km	Distancia estimada a la IES.

Cuadro 1: Variables socio-demográficas y geográficas.

Variable	Tipo de Dato	Tipo Rango	Rango Original	Descripción
promedio_academico	Numérica (Continuo)	Continuo	[0,87 – 5,00]	Promedio acumulado (escala 0.0-5.0).
materias_reprobadas	Numérica (Entero)	Discreto	[0 – 12] materias	Acumulado de materias reprobadas.
puntaje_icfes_percentil	Numérica (Entero)	Discreto	[1 – 100] percentil	Percentil obtenido en Saber 11.
semestre_cursado	Numérica (Entero)	Discreto	[1 – 12] semestres	Semestre actual matriculado.
nivel_formacion	Categórica	Nominal	3 niveles	Nivel del programa académico.
metodologia	Categórica	Nominal	3 modalidades	Modalidad de impartición.
area_conocimiento	Categórica	Nominal	8 áreas	Área disciplinar del programa.

Cuadro 2: Variables académicas del estudiante.

Variable	Tipo de Dato	Tipo Rango	Rango Original	Descripción
estrato_socioeconomico	Numérica (Entero)	Ordinal	[1 – 6]	Estrato residencial del estudiante.
nivel_educativo_padre	Categórica	Ordinal	6 niveles	Nivel educativo del padre.
nivel_educativo_madre	Categórica	Ordinal	6 niveles	Nivel educativo de la madre.
sector_ies	Categórica	Nominal	'Público', 'Privado'	Sector de la institución IES.
trabaja_mientras_estudia	Numérica (Binario)	Binario	0 (No), 1 (Sí)	Indicador de empleo simultáneo.
beneficiario_icetex	Numérica (Binario)	Binario	0 (No), 1 (Sí)	Indicador de apoyo ICETEX.
beneficiario_beca	Numérica (Binario)	Binario	0 (No), 1 (Sí)	Indicador de beca institucional.
anio_registro	Numérica (Entero)	Discreto	[2021 – 2025]	Año de ingreso a la cohorte.

Cuadro 3: Variables socioeconómicas, familiares y financieras.

$$\begin{aligned}
R_i = & 2,5 \cdot \mathbb{I}(\text{promedio} < 3,0) + 2,5 \cdot \mathbb{I}(\text{reprobadas} \geq 2) \\
& + 1,0 \cdot \mathbb{I}(\text{icfes} < 40) + 1,0 \cdot \mathbb{I}(\text{trabaja} = 1) \\
& + 0,5 \cdot \mathbb{I}(\text{beca} = 0) + 0,5 \cdot \mathbb{I}(\text{estrato} \leq 2)
\end{aligned} \tag{1}$$

La regla de decisión asigna la etiqueta de deserción mediante el umbral crítico de 3,5 puntos:

$$\text{desercion}_i = \begin{cases} 1 & \text{si } R_i \geq 3,5 \quad (\text{Deserción: } 33.59 \%) \\ 0 & \text{si } R_i < 3,5 \quad (\text{Permanencia: } 66.41 \%) \end{cases} \tag{2}$$

4. Estadísticas Descriptivas Pre-Normalización

La Tabla 4 sintetiza las métricas descriptivas calculadas sobre las 11,500 observaciones originales:

Variable	Media	Desv. Est.	Mínimo	Mediana	Máximo	Rango Original
edad_ingreso	19.57	2.96	15.00	19.00	32.00	[15,00 – 32,00]
promedio_academico	3.41	0.63	0.87	3.41	5.00	[0,87 – 5,00]
materias_reprobadas	1.09	1.20	0.00	1.00	12.00	[0,00 – 12,00]
distancia_hogar_ies_km	11.12	12.52	0.22	7.43	250.00	[0,22 – 250,00]
puntaje_icfes_percentil	57.96	17.80	1.00	58.00	100.00	[1,00 – 100,00]
semestre_cursado	6.53	3.44	1.00	7.00	12.00	[1,00 – 12,00]
estrato_socioeconomico	2.61	1.20	1.00	2.00	6.00	[1,00 – 6,00]
anio_registro	2023.31	1.27	2021.00	2023.00	2025.00	[2021,00 – 2025,00]
trabaja_mientras_estudia	0.38	0.48	0.00	0.00	1.00	[0,00 – 1,00]
beneficiario_icitex	0.22	0.41	0.00	0.00	1.00	[0,00 – 1,00]
beneficiario_beca	0.19	0.39	0.00	0.00	1.00	[0,00 – 1,00]

Cuadro 4: Estadísticas descriptivas de las variables numéricas originales.

5. Justificación del Escalamiento para SVM

El clasificador SVM con **Kernel RBF** calcula la norma euclidiana $\|x - x'\|^2$:

$$K(x, x') = \exp(-\gamma \|x - x'\|^2) \tag{3}$$

Debido a la disparidad entre la variable `distancia_hogar_ies_km` ($\Delta = 249,78$) y `promedio_academico` ($\Delta = 4,13$), el término de norma euclidiana se sesga hacia las características de mayor magnitud sin escalamiento previo, afectando la frontera de decisión.

6. Configuración e Hiperparámetros de SVM (SVC)

Se empleó la siguiente configuración del estimador **SVC**:

$$\text{SVC}(\text{kernel} = \text{'rbf'}, C = 1,0, \gamma = \text{'scale'}, \text{cache_size} = 1000, \text{random_state} = 42) \tag{4}$$

- **Kernel RBF**: Modela fronteras no lineales complejas mediante espacio característico de dimensión infinita.
- **Margen Blando** $C = 1,0$: Ofrece un balance estándar entre ancho de margen y tolerancia de errores.

- **Coefficiente $\gamma = \text{'scale'}$:** Ajusta automáticamente $\gamma = \frac{1}{n_features \cdot \text{Var}(X)}$.
- **Caché RAM = 1000 MB:** Acelera la optimización cuadrática en el dataset de 11,500 registros.

7. Métodos de Normalización Evaluados y Resultados

La Tabla 5 resume el desempeño comparativo en 10 iteraciones independientes de validación cruzada:

Método de Normalización	Fórmula	F1-Score	Desv. Est.	P-Valor vs Baseline
Power Transformer (Yeo-Johnson)	Transformación potencia $g_\lambda(x)$	0.908516	0.006546	$1,35 \times 10^{-20}$
Standard Scaler	$z = (x - \mu)/\sigma$	0.905890	0.007009	$2,57 \times 10^{-20}$
Quantile Transformer	$x' = G^{-1}(F_{emp}(x))$	0.843320	0.008075	$1,75 \times 10^{-19}$
Min Max Scaler	$x' = (x - x_{\min})/(x_{\max} - x_{\min})$	0.837759	0.010349	$1,73 \times 10^{-18}$
Max Absolute Scaler	$x' = x/ x_{\max} $	0.836626	0.008938	$4,69 \times 10^{-19}$
Sin Normalización (Baseline)	$x' = x$	0.000000	0.000000	1,00

Cuadro 5: Resultados empíricos de clasificación SVM bajo distintos escalamientos.

8. Conclusiones

La normalización de datos es indispensable para obtener hiperplanos generalizables en SVM. Los métodos que ajustan la varianza y normalidad (**PowerTransformer** y **StandardScaler**) obtienen el rendimiento más alto ($F1 > 0,90$).