Arnold Santiago Torres Anzola
Sara López Chavarro
Nicolás Figueroa Salgado

Universidad Externado de Colombia
Departamento de Matemáticas — Pregrado en Ciencia de Datos

Noviembre de 2026

Artículo Base de Referencia: Boteju, G., Tang, L., & Scott Brown, M. (IEEE BigData, 2024). *Support Vector Machine for Predicting Student Dropout Under Different Normalization Methods*.

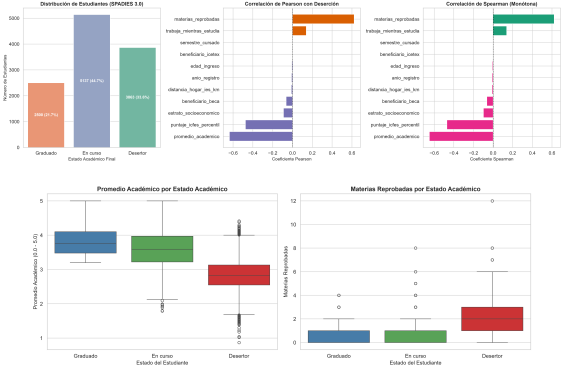
1. Estrategia de Datos: Fundamentación SPADIES 3.0 y EDA

Dataset y Formulación Multiclase

- **Cohorte:** 11,500 estudiantes, 21 variables predictoras (académicas, socioeconómicas e institucionales).
- **3 Estados Reales (SPADIES 3.0 - MEN):**
  - **En curso (44.7 %):** Avance regular (5,137 est.).
  - **Desertor (33.6 %):** Retiro $\geq$ 2 semestres (3,863 est.).
  - **Graduado (21.7 %):** Culminación exitosa (2,500 est.).

Hallazgo Estadístico Clave: No Linealidad

- Spearman > Pearson en `promedio` y `reprobadas`.
- El abandono opera por **efecto umbral** (caer de 3.0 dispara el riesgo), justificando el uso de un

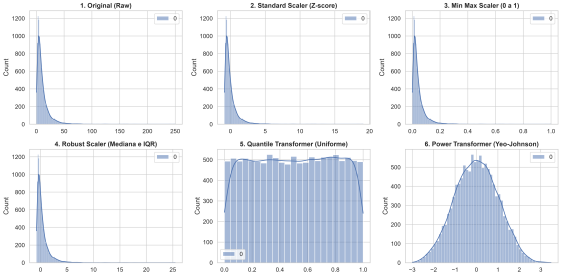


2. Metodología: La Sensibilidad Geométrica de SVM y el Escalado

Dependencia Geométrica del Kernel RBF

$$K(x_i, x_j) = \exp\left(-\gamma \|x_i - x_j\|^2\right)$$

- Si no se escala, variables con magnitudes amplias dominan la norma euclidiana $\|x_i - x_j\|^2$.
- Caso crítico: `distancia_hogar_ies_km` (Skewness $= +5{,}05$, valores hasta 250 km) apaga al `promedio_academico` ($0{,}0 - 5{,}0$).

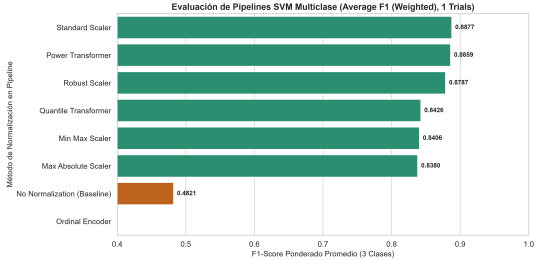


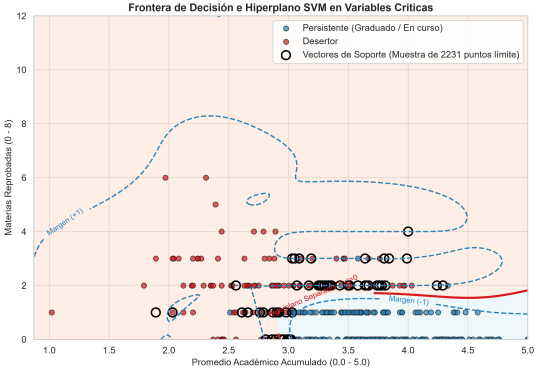
figureComportamiento de `distancia_hogar_ies_km` ante 6 transformadores.

Validación Experimental Rigurosa

- **50 Particiones Monte Carlo** independientes (80 % entrenamiento / 20 % prueba estratificada).
- **Sin fuga de datos (*data leakage*):** Ajuste estricto dentro de un `Pipeline` de Scikit-Learn

3. Resultados: Ranking de Normalizadores y Frontera Nítida





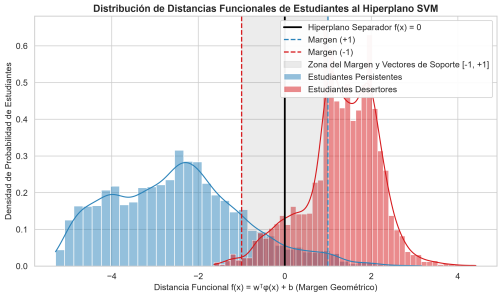
Impacto Cuantitativo (50 Trials)

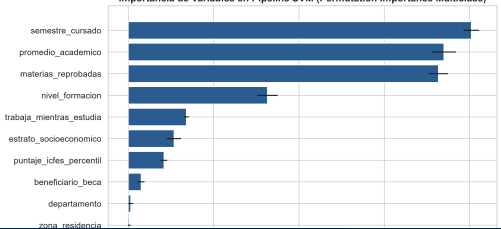
- **Colapso Baseline:** $F_1 = 0{,}4097 \pm 0{,}006$ (sin escalar).
- **StandardScaler / Power:** $F_1 = \mathbf{0{,}8878} \pm 0{,}006$ (+85 % de mejora, $t > 48{,}7$, $p < 10^{-6}$).
- **Recall de Desertores: 92,11 %** (solo 7,89 % falsos negativos).

Lectura Institucional de la Frontera

- **Línea roja** $f(x) = 0$: Umbral exacto que activa alerta temprana.
- **Vectores de soporte (halos): Estudiantes en riesgo límite / cuerda floja** (promedio $\sim$ 3,0, 1 o 2 reprobadas) $\rightarrow$ Máxima prioridad de tutoría.

4. Conclusiones y Aplicación en Bienestar Universitario





Estratificación del Riesgo con Distancia $f(x)$

- **Deserción Consolidada ($f(x) < -1$, 28.3 %):** Readmisión y homologación.
- **Margen Crítico / Vectores de Soporte ($|f(x)| \leq 1$, 19.4 %): Foco de Bienestar** para intervención antes de semana 6.
- **Permanencia Segura ($f(x) > +1$, 52.3 %):** Avance regular.

Recomendaciones Clave para la Universidad

1. **Preprocesamiento Estructural:** La normalización define la existencia del margen en SVM.
2. **Ventana Crítica Temprana:** `semestre_cursado` es la variable #1 ($\Delta F_1 \approx 0{,}201$); intervenir en semestres 1 a 3.
3. **Auditoría de Equidad (Fairness):** Brecha de detección $< 4\,\%$ entre subgrupos (sexo, rural/urbano).