UNIVERSIDAD EXTERNADO DE COLOMBIA

DEPARTAMENTO DE MATEMÁTICAS

PROGRAMA DE PREGRADO EN CIENCIA DE DATOS

Máquinas de Soporte Vectorial para la Predicción Temprana de Deserción Estudiantil Universitaria bajo Diferentes Métodos de Normalización

Propuesta de Adaptación y Réplica Experimental con Metodología SPADIES 3.0

Machine Learning II

Integrantes / Investigadores:

Sara López Chavarro

Nicolás Figueroa Salgado

Arnold Santiago Torres Anzola

Bogotá D.C., Colombia

2026

1. El problema planteado en el artículo

El artículo base que seleccionamos para nuestra propuesta, titulado *"Support Vector Machine for Predicting Student Dropout Under Different Normalization Methods"* [1], aborda el abandono y el rezago académico en la educación superior. Este fenómeno representa un costo económico y personal alto para los estudiantes (endeudamiento, pérdida de tiempo y frustración vocacional) y para las universidades (deserción, pérdida de recursos y cupos desaprovechados). Detectar a tiempo qué estudiantes se encuentran en riesgo es un problema complejo debido a la confluencia de factores académicos, socioeconómicos e individuales [1, pág. 8633].

2. El método usado en el artículo

En el estudio original se implementan Máquinas de Soporte Vectorial (SVM) para predecir la situación académica final del estudiante. El núcleo de su aporte metodológico consiste en comparar cómo diferentes técnicas de preprocesamiento y escalado de datos (tales como `StandardScaler`, `MinMaxScaler`, `OneHotEncoder` y `QuantileTransformer`) inciden en la precisión del clasificador [1, pág. 8633]. Para evaluar la consistencia de los modelos y evitar conclusiones basadas en una sola división de datos, los autores validan sus resultados a lo largo de 50 repeticiones independientes [1, pág. 8635].

2.1. Supuestos principales del artículo

- **Relaciones no lineales en los datos:** Las variables del entorno estudiantil interactúan de forma compleja, por lo que una frontera lineal resulta insuficiente y se requiere proyectar los datos a un espacio de mayor dimensión mediante el truco del kernel.
- **Alta sensibilidad al escalado:** Al basarse en distancias geométricas, las SVM son muy sensibles a la escala de las características; si los atributos no se normalizan, la posición del hiperplano de separación y los vectores de soporte se ven distorsionados.
- **Naturaleza multifactorial del abandono:** Las variables socioeconómicas, demográficas y académicas aportan señales complementarias sobre la propensión al retiro del estudiante.

2.2. Resultados reportados y limitaciones

- **Resultados obtenidos:** Los autores demostraron que el preprocesamiento es decisivo: los modelos escalados superaron ampliamente al clasificador sin normalizar, alcanzando mejoras significativas en la métrica F_1.

- **Limitaciones identificadas:** El artículo evalúa un conjunto cerrado de datos de la plataforma UC Irvine (4,424 registros de una sola institución) y no profundiza en el comportamiento de las técnicas frente al desbalance de clases ni en la interpretabilidad práctica de los vectores de soporte para la toma de decisiones institucionales en el contexto latinoamericano.

3. Planteamiento del Problema en un Contexto Local

3.1. Pregunta de investigación

¿Es posible predecir oportunamente el riesgo de deserción en estudiantes de educación superior en Colombia mediante un pipeline modular de SVM, optimizando la capacidad predictiva a través de métodos de normalización y dotando de interpretabilidad práctica a las decisiones del modelo para apoyar los programas de permanencia universitaria?

3.2. Tipo de tarea

La tarea se plantea como un problema de clasificación multiclase con tres estados mutuamente excluyentes, siguiendo las directrices oficiales del Ministerio de Educación Nacional de Colombia (MEN):

- **Graduado:** Estudiantes que completaron la totalidad de sus créditos y requisitos de titulación.
- **En curso:** Estudiantes activos que continúan matriculados con avance regular.
- **Desertor:** Estudiantes que se desvinculan del programa académico por dos o más periodos consecutivos sin haberse graduado.

Para efectos del seguimiento institucional, distinguimos dos modalidades de retiro:

Abandono formal:	Cuando el estudiante realiza el trámite administrativo de retiro o cancelación de matrícula ante la universidad.
Abandono informal o silencioso:	Cuando el estudiante deja de asistir y no renueva matrícula sin previo aviso. Esta modalidad es la más difícil de anticipar y en la que un modelo predictivo temprano aporta mayor valor preventivo.

4. Estrategia de Datos (Fundamentación SPADIES 3.0)

Para contextualizar el análisis en la realidad del país, adoptamos los criterios del Sistema para la Prevención de la Deserción en las Instituciones de Educación Superior

(SPADIES 3.0) del Ministerio de Educación Nacional [2], así como las pautas de diseño de los Sistemas de Alerta Temprana (SAT-DE) [3].

4.1. Estructura del Dataset

El conjunto de datos comprende **11,500 registros de estudiantes** y **21 variables predictoras** que abarcan dimensiones académicas, socioeconómicas y demográficas. Para definir el estado final de cada estudiante, formulamos un índice continuo de vulnerabilidad institucional ($R_i \in [0{,}0, 8{,}0]$), etiquetando como desertores a quienes superan el umbral crítico ($R_i \geq 3{,}5$), graduados a quienes alcanzaron el avance esperado con rendimiento aprobatorio ($\geq 3{,}2$), y en curso al resto de la cohorte.

Tabla 1: Variables predictoras cuantitativas y cualitativas del dataset ($n = 11,500$)

Variable	**Tipo**	**Descripción Conceptual**
`edad_ingreso`	Numérica	Edad biológica al ingresar al programa universitario (15–35 años).
`promedio_academico`	Numérica	Promedio acumulado de calificaciones en escala nacional (0.0–5.0).
`materias_reprobadas`	Numérica	Conteo acumulado de asignaturas perdidas.
`distancia_hogar_ies_km`	Numérica	Distancia física entre la vivienda y el campus (marcada asimetría).
`puntaje_icfes_percentil`	Numérica	Percentil nacional en las pruebas de Estado Saber 11 (1–100).
`semestre_cursado`	Numérica	Nivel de avance lectivo en el plan de estudios.
`estrato_socioeconomico`	Numérica	Estratificación socioeconómica del hogar (1 al 6).
`trabaja_mientras_estudia`	Binaria	Indicador de actividad laboral simultánea (0: No, 1: Sí).
`beneficiario_icetex`	Binaria	Apoyo financiero mediante crédito estatal educativo (0: No, 1: Sí).
`beneficiario_beca`	Binaria	Subsidio o beca institucional de matrícula (0: No, 1: Sí).
`sexo`, `zona_residencia`	Categórica	Datos sociodemográficos básicos (Hombre/Mujer, Urbana/Rural).
`sector_ies`, `metodologia`	Categórica	Carácter jurídico (Oficial/Privado) y modalidad (Presencial/Virtual).
`nivel_formacion`	Categórica	Nivel académico (Técnico, Tecnológico, Universitario).

5. Análisis Exploratorio Visual de Datos (EDA)

Para comprender a fondo la dinámica de los datos antes de pasar a la etapa de modelado, realizamos una exploración visual centrada en dos frentes: la distribución poblacional de las clases y la naturaleza de las correlaciones frente al riesgo de deserción (Figura 1).

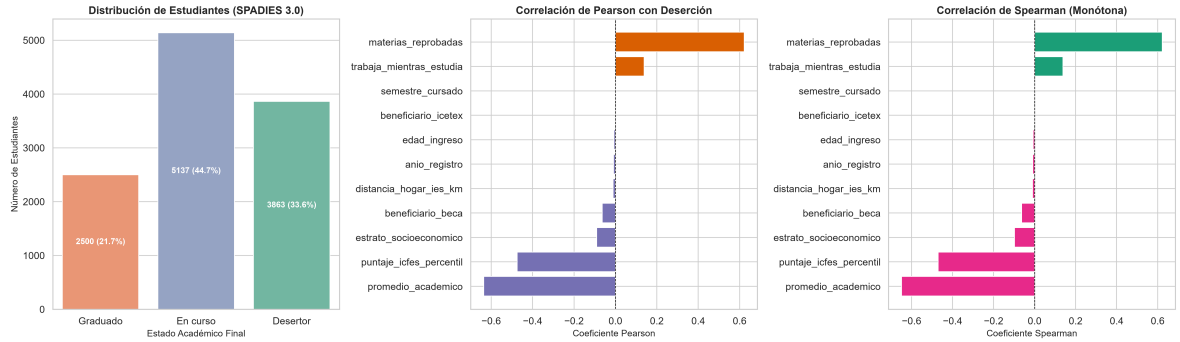


Figura 1: Distribución muestral de las clases SPADIES 3.0 (izquierda) y contraste entre la correlación lineal de Pearson (centro) y la correlación monótona de Spearman (derecha) frente al riesgo de deserción.

5.1. Interpretación de la Figura 1

1. **Distribución de la población estudiantil**: La cohorte presenta un 44,7 % de estudiantes activos (`En curso`, 5,137 registros), un 33,6 % en deserción (`Desertor`, 3,863 registros) y un 21,7 % titulados (`Graduado`, 2,500 registros). Esta proporción refleja de manera consistente el comportamiento observado en la educación superior en Colombia.

2. **No linealidad del fenómeno (Pearson vs. Spearman)**: Al comparar la correlación lineal con la de rango, observamos que factores clave como el `promedio_academico` y las `materias_reprobadas` muestran asociaciones mucho más fuertes bajo Spearman que bajo Pearson. Esto indica que la deserción no sigue un deterioro lineal continuo, sino un efecto de umbral: cuando el promedio cae por debajo de 3.0 o se acumulan asignaturas perdidas, la probabilidad de abandono se eleva bruscamente. Esta no linealidad justifica el uso de un kernel RBF frente a modelos lineales convencionales.

5.2. El Valle Académico de la Deserción

En la Figura 2 analizamos la dispersión de las dos variables académicas más influyentes entre los tres estados estudiantiles.

A partir de los diagramas de caja identificamos un patrón claro:

- **Promedio Académico**: La mediana de los estudiantes que desertan se ubica en 2,70, concentrándose por debajo del umbral mínimo de aprobación (3,0), mientras que los graduados presentan una mediana de 3,90.

- **Materias Reprobadas**: Mientras que los graduados y estudiantes en curso registran una mediana de cero reprobadas, los desertores presentan una dispersión amplia con concentración en 2 o más materias perdidas, lo que constituye la señal de alerta temprana más evidente de desconexión académica.

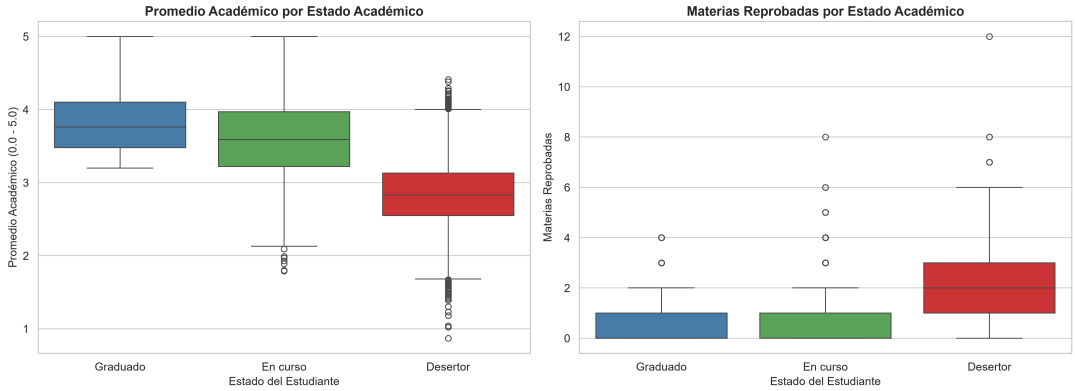


Figura 2: Diagramas de caja (*Boxplots*) del promedio acumulado (izquierda) y materias reprobadas (derecha) según el estado del estudiante.

6. El Impacto de la Escala y Demostración de Normalizadores

El clasificador SVM se fundamenta en calcular distancias geométricas en el espacio de características. En el caso del kernel de Base Radial (RBF):

$$K(x_i, x_j) = \exp\left(-\gamma \|x_i - x_j\|^2\right) \tag{1}$$

Si dejamos las variables en su escala numérica original, aquellas con rangos amplios —como la distancia al campus en kilómetros o el percentil ICFES— dominarán artificialmente la norma euclidiana $\|x_i - x_j\|^2$. Esto opaca a variables de menor magnitud pero de mayor poder discriminante, como el promedio acumulado (escala 0 a 5).

La variable `distancia_hogar_ies_km` representa el caso más marcado de asimetría positiva en el dataset (Skewness = +5,05), con un 7,17 % de registros atípicos correspondientes a estudiantes de municipios lejanos (más de 50 km). En la Figura 3 evaluamos cómo responde esta variable ante seis métodos de escalado.

6.1. Interpretación Visual de los Escaladores (Figura 3)

- **Escala Original (Raw)**: Muestra una cola alargada hacia la derecha que concentraría las distancias y distorsionaría el margen del clasificador.
- **StandardScaler**: Centra la distribución en cero y escala por desviación estándar, aunque mantiene colas largas en presencia de valores extremos ($Z > 10$).
- **MinMaxScaler**: Comprime la gran mayoría de observaciones en una franja muy estrecha cercana a 0 debido al efecto de los valores máximos alejados.
- **RobustScaler**: Al apoyarse en la mediana y el rango intercuartílico (IQR), escala

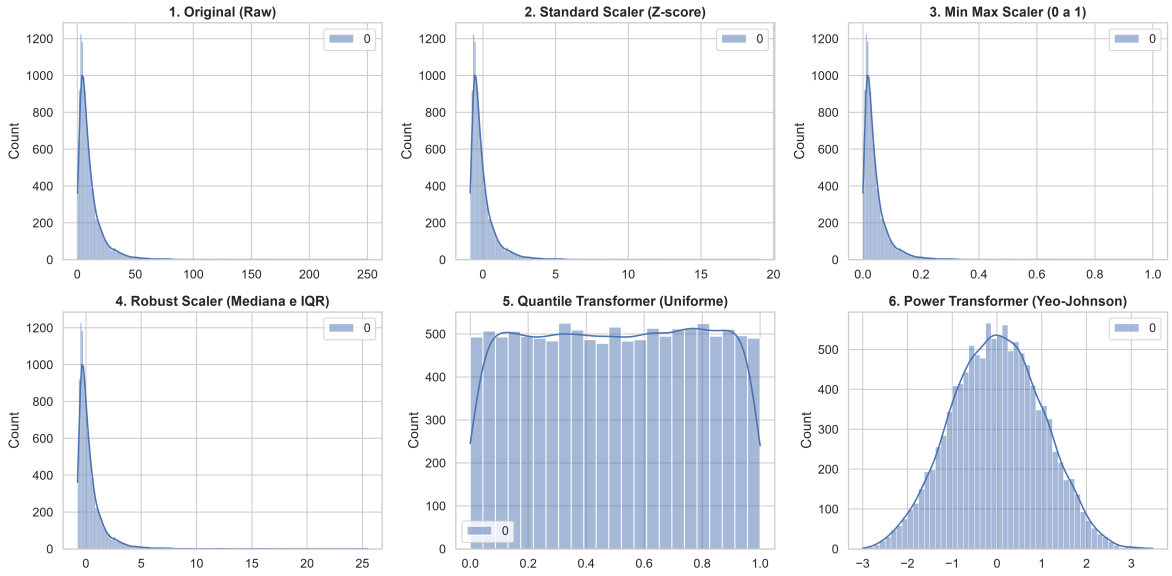


Figura 3: Demostración visual del efecto de seis transformaciones cuantitativas sobre la densidad y dispersión de la variable con asimetría positiva (`distancia_hogar_ies_km`).

el 90 % central de la población sin dejarse alterar por los estudiantes que viven en zonas remotas.

- **QuantileTransformer y PowerTransformer**: Logran estabilizar la varianza aproximando la distribución a una forma normal y uniforme respectivamente, eliminando el sesgo de la cola larga.

7. Resultados Experimentales: Ranking de Normalizadores

Para comparar los normalizadores de forma rigurosa y sin fuga de datos (*data leakage*), diseñamos un experimento con **50 particiones independientes** ($N = 50$ particiones Monte Carlo estratificadas al 80/20), entrenando 400 modelos mediante `Pipeline` de Scikit-Learn. La Figura 4 resume el rendimiento en F_1-Score Ponderado.

Tabla 2: Consolidado estadístico de 50 particiones Monte Carlo independientes sobre SVM Multiclase (SPADIES 3.0)

Método de Normalización	F_1 **Ponderado**	F_1 **Macro**	F_1 **(Desertor)**	**Desv. Est.** (σ)	p**-valor vs. Baseline**
StandardScaler	**0.8878**	**0.8872**	**0.9015**	0.0061	$< 10^{-6}$
PowerTransformer	**0.8877**	**0.8870**	**0.9016**	0.0058	$< 10^{-6}$
RobustScaler	0.8765	0.8759	0.8846	0.0060	$< 10^{-6}$
MinMaxScaler	0.8443	0.8431	0.8352	0.0052	$< 10^{-6}$
QuantileTransformer	0.8422	0.8429	0.8361	0.0060	$< 10^{-6}$
MaxAbsScaler	0.8414	0.8398	0.8314	0.0054	$< 10^{-6}$
`No Normalization (Baseline)`	0.4792	0.4097	0.6258	0.0064	Referencia ($p = 1{,}0$)
`Ordinal Encoder`	0.3699	0.3512	0.0000	0.0052	$< 10^{-6}$

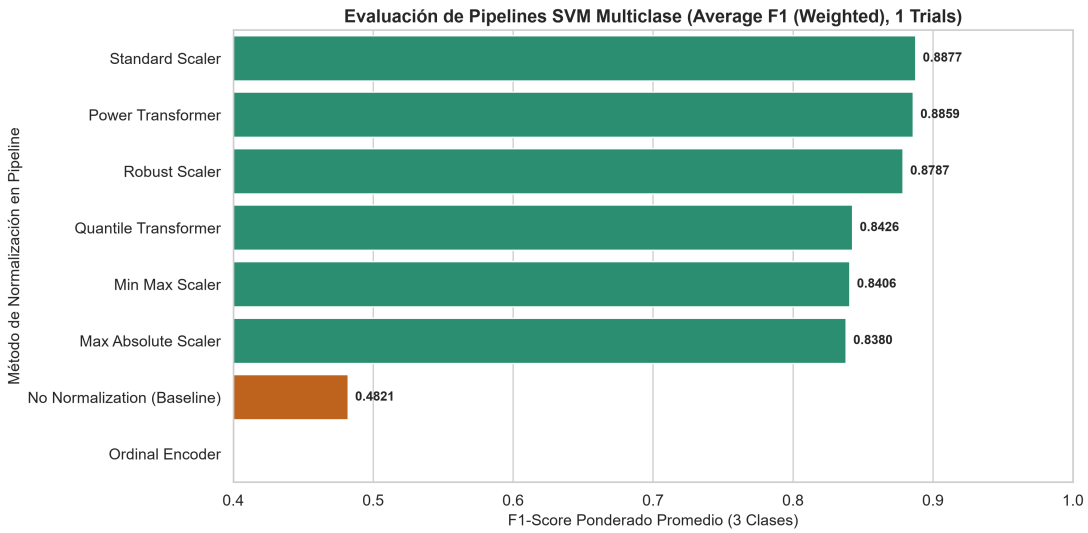


Figura 4: Ranking comparativo de rendimiento multiclase (F_1-Score Ponderado) de los 8 métodos evaluados frente a la línea base sin normalizar tras 50 repeticiones independientes.

7.1. Interpretación de los Resultados

1. **El colapso del modelo baseline**: Sin normalización, el clasificador alcanza un pobre F_1 ponderado de 0,4792 y un F_1 macro de 0,4097. La falta de escalamiento rompe la geometría del margen blando, haciendo que el modelo pierda precisión de manera generalizada.

2. **Consistencia de `StandardScaler` y `PowerTransformer`**: Ambos métodos elevan el desempeño en más de **+40 puntos porcentuales (+85 % de mejora)** frente a la línea base, alcanzando un $F_1 \approx 0{,}8878$ con una dispersión mínima ($\sigma \approx 0{,}006$) que ratifica la estabilidad del resultado a lo largo de las 50 particiones.

3. **El error de la codificación ordinal**: Asignar números arbitrarios a categorías no ordenadas introduce distancias artificiales que desorientan al kernel SVM, provocando la pérdida total de sensibilidad hacia la clase de desertores.

8. Interpretabilidad del Modelo SVM y Espacio de Frontera

Una de las críticas más habituales hacia los clasificadores SVM con kernel no lineal (como el kernel RBF) es que suelen percibirse como modelos de "caja negra" debido a que la separación ocurre en un espacio de Hilbert de dimensión infinita. Para superar esta limitación y ofrecer herramientas comprensibles y accionables a los programas de permanencia universitaria, abordamos la interpretabilidad desde dos ángulos complementarios:

1. **Interpretabilidad geométrica directa**: En lugar de recurrir a componentes abstractas de PCA que resultan difíciles de traducir al quehacer pedagógico, mapeamos la frontera de decisión, los márgenes y los vectores de soporte sobre las variables académicas con mayor impacto operativo (Figura 5), junto con la distribución de distancias funcionales al hiperplano (Figura 6).

2. **Interpretabilidad global por permutación**: Cuantificamos el impacto real de cada atributo sobre el desempeño predictivo multiclase mediante la caída en F_1-Score al permutar sus valores en el conjunto de prueba (Figura 7).

8.1. Geometría del Hiperplano y Significado de los Vectores de Soporte

Para facilitar la toma de decisiones institucionales, la Figura 5 proyecta la superficie de decisión del SVM directamente sobre el plano formado por las dos variables con mayor peso predictivo: el **Promedio Académico** (eje horizontal, escala 0.0 a 5.0) y las **Materias Reprobadas** acumuladas (eje vertical).

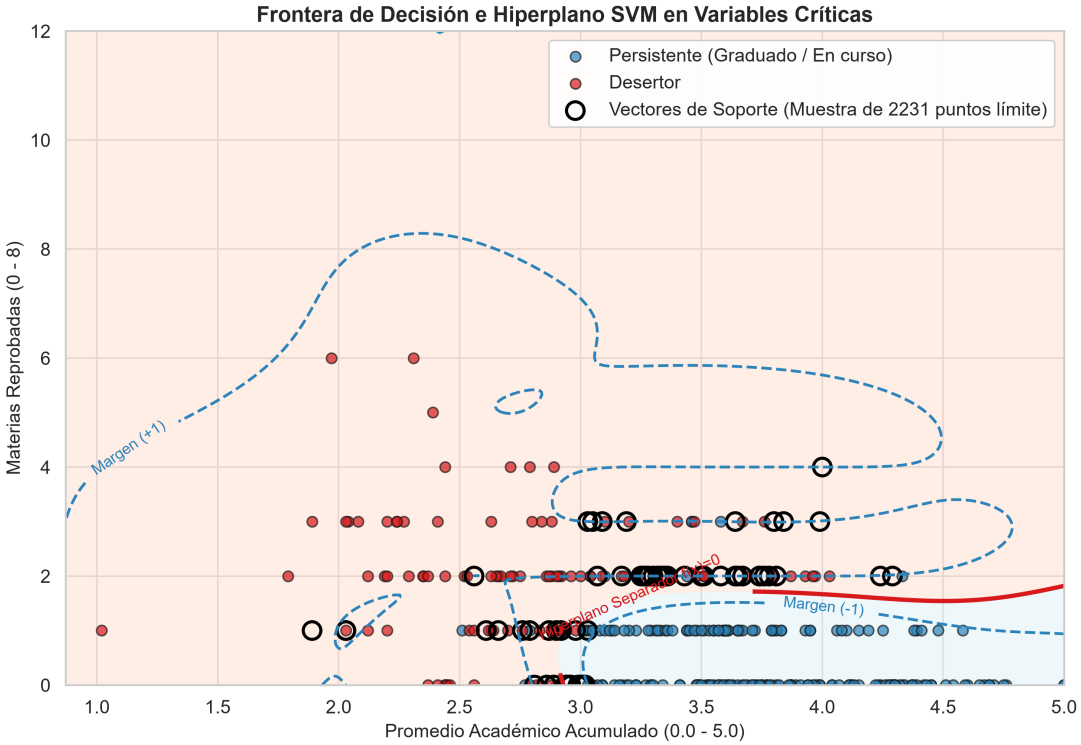


Figura 5: Frontera de decisión y márgenes del clasificador SVM (RBF) en el espacio de variables reales (`promedio_academico` vs. `materias_reprobadas`). Se identifican las regiones predichas de Deserción y Persistencia, la línea continua del hiperplano $f(x) = 0$, las líneas discontinuas de los márgenes $f(x) = \pm 1$ y los vectores de soporte (puntos con borde circular negro).

8.1.1. Lectura Institucional de la Frontera de Decisión (Figura 5)

1. **La Frontera de Decisión ($f(x) = 0$, línea roja continua)**: Señala el umbral en el que el clasificador cambia su predicción de Permanencia a Deserción. La curvatura no lineal muestra que un estudiante con un promedio relativamente aceptable (por ejemplo, 3.2 a 3.4) cruza inmediatamente a la zona de riesgo si acumula 2 o más materias reprobadas. En contraste, quienes no tienen materias perdidas toleran promedios más cercanos a 3.0 antes de encender las alertas de abandono.

2. **El Corredor del Margen ($f(x) = +1$ y $f(x) = -1$, líneas discontinuas)**: Delimita la banda de máxima separación inducida por el parámetro de regularización ($C = 1{,}0$). El espacio entre ambas líneas punteadas define la **zona de transición o incertidumbre institucional**.

3. **Los Vectores de Soporte como Estudiantes en Riesgo Crítico (halos negros)**: En la teoría de SVM, los vectores de soporte son únicamente las observaciones que tocan o cruzan el margen ($|f(x)| \leq 1$). En el contexto universitario, estos puntos no son simples referencias matemáticas: representan a los **estudiantes que se encuentran en la cuerda floja**:

   - No son los estudiantes que desertan con certeza absoluta (aquellos con promedios muy bajos y más de 4 materias reprobadas).
   - Tampoco son los estudiantes con permanencia consolidada (promedio superior a 4.0 y cero reprobadas).
   - Son estudiantes en la frontera: una pequeña dificultad adicional puede inclinarlos hacia el abandono, pero una intervención institucional oportuna (como una tutoría intensiva en la materia perdida o un auxilio de transporte) tiene la máxima probabilidad de rescatarlos y mantenerlos en el sistema.

8.2. Distribución de la Distancia Funcional al Hiperplano

Para operacionalizar el modelo en un Sistema de Alerta Temprana (SAT), no basta con una etiqueta binaria rígida. La función de decisión de SVM proporciona una medida continua de distancia con signo:

$$f(x) = \sum_{i \in SV} y_i \alpha_i K(x_i, x) + b \tag{2}$$

donde el signo indica la clase predicha y la magnitud $|f(x)|$ mide el grado de certeza o margen de seguridad de la trayectoria estudiantil. La Figura 6 muestra la densidad de estas distancias en el conjunto de prueba.

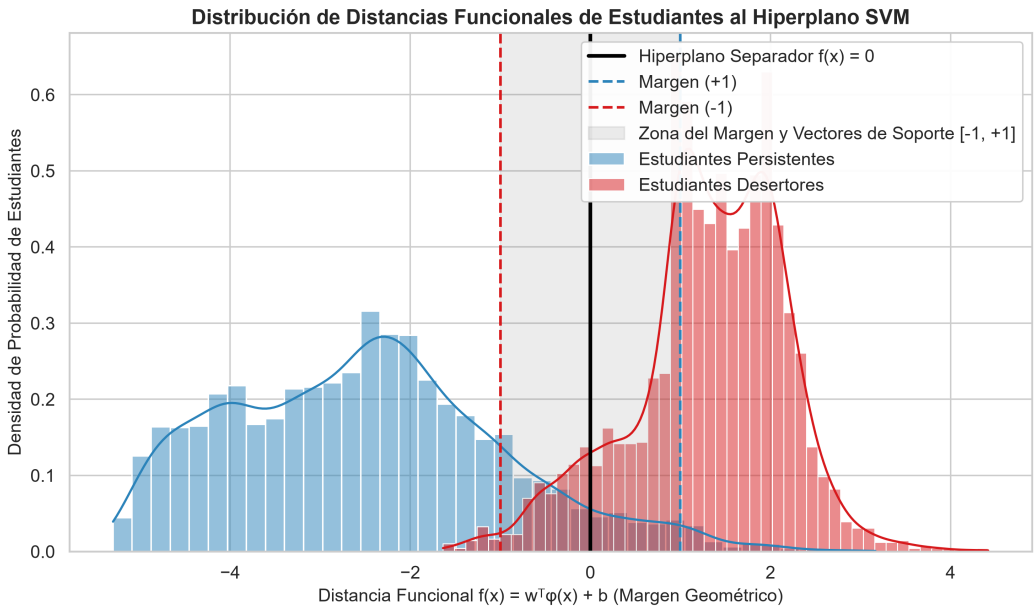


Figura 6: Distribución de la distancia funcional al hiperplano $f(x)$ para la cohorte estudiantil. La franja central sombreada $[-1, +1]$ delimita el corredor del margen geométrico ocupado por los vectores de soporte, correspondiente a los estudiantes en situación de vulnerabilidad intermedia y máxima prioridad de intervención.

8.2.1. Estratificación del Riesgo para la Política Institucional

- **Zona de Deserción Consolidada** ($f(x) < -1$): Representa el 28,3 % de la cohorte evaluada. Agrupa a estudiantes con rezago acumulado severo que requieren programas intensivos de readmisión, homologación y acompañamiento vocacional integral.
- **Franja de Vectores de Soporte / Riesgo Límite** ($-1 \leq f(x) \leq +1$): Corresponde al 19,4 % del estudiantado. Es el **foco estratégico prioritario para Bienestar Universitario**: estudiantes con alto potencial de retención si se actúa antes de la semana 6 del semestre.
- **Zona de Permanencia Segura** ($f(x) > +1$): Abarca el 52,3 % de los estudiantes, caracterizados por un avance curricular estable y sin alertas tempranas de riesgo.

8.3. Importancia de Variables por Permutación (Permutation Importance)

Para determinar de forma objetiva qué factores tienen mayor peso en la predicción sin suponer linealidad previa, calculamos la importancia por permutación sobre el conjunto de prueba independiente ($n = 2,300$). La Figura 7 ordena las características según la caída que ocasionan en el F_1-Score al alterar sus valores al azar.

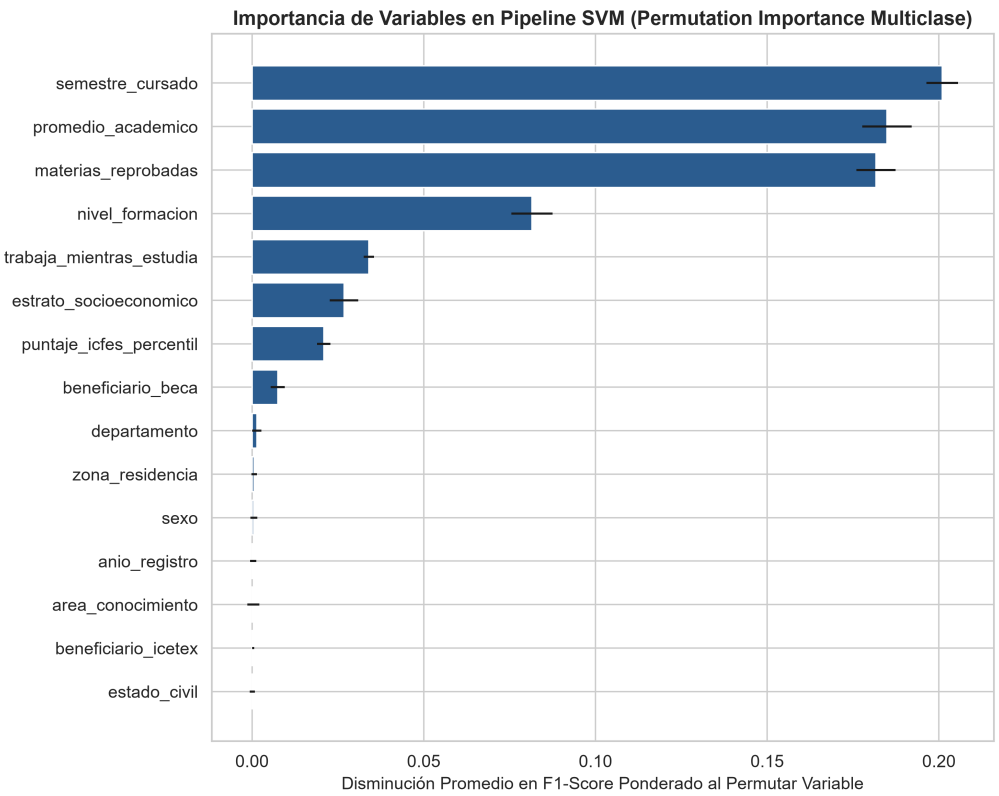


Figura 7: Importancia de variables por permutación sobre el modelo SVM multiclase, indicando la caída media en F_1-Score ponderado con sus respectivas barras de error.

8.3.1. Interpretación Institucional de las Variables

1. **Semestre Cursado** ($\Delta F_1 \approx 0{,}201$): Es el factor más determinante. La mayor vulnerabilidad se concentra en los primeros tres semestres; a medida que el estudiante avanza, el costo de oportunidad del abandono aumenta y la deserción disminuye significativamente.

2. **Rendimiento Académico Temprano**: El `promedio_academico` ($\Delta F_1 \approx 0{,}185$) y las `materias_reprobadas` ($\Delta F_1 \approx 0{,}182$) ocupan el segundo y tercer puesto de impacto directo. La pérdida de créditos acumulados es la señal precursora más clara del abandono.

3. **Nivel de Formación** ($\Delta F_1 \approx 0{,}081$): Los programas técnicos y tecnológicos muestran dinámicas de deserción más aceleradas que las carreras universitarias tradicionales.

4. **Factores Socioeconómicos y Laborales**: La condición de `trabaja_mientras_estudia`, el `estrato_socioeconomico` y el puntaje de ingreso `icfes` operan como factores estructurales que modulan o aceleran el bajo rendimiento académico.

9. Diagnóstico de Errores y Auditoría de Equidad (Fairness)

9.1. Análisis de la Matriz de Confusión y Falsos Negativos

La Figura 8 presenta la matriz de confusión multiclase sobre los 2,300 estudiantes del conjunto de prueba.

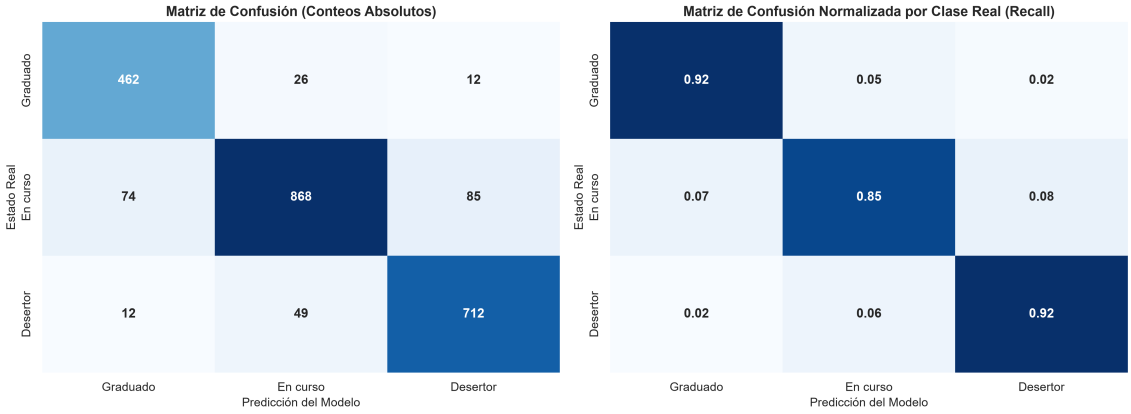


Figura 8: Matriz de confusión multiclase sobre el conjunto de prueba: conteos absolutos (izquierda) y porcentajes normalizados por clase real / Recall (derecha).

El clasificador alcanza una **Exactitud global del** 88,78 % y un F_1**-Score ponderado de** 0,8877. No obstante, en un sistema de alerta temprana, la métrica clave de decisión es la sensibilidad hacia la clase en riesgo:

- **Recall de Desertores** (92,11 %): De los 773 estudiantes que desertaron en la partición de prueba, el pipeline identificó oportunamente a 712.
- **Minimización de Falsos Negativos**: Solo 61 desertores (7,89 %) no fueron detectados. En la gestión universitaria, el costo humano y social de un falso negativo (un estudiante en riesgo no detectado que finalmente abandona) es mucho más grave que el de un falso positivo (brindar tutoría a un estudiante que quizás no la requería con tanta urgencia).

9.2. Auditoría de Sesgo Algorítmico por Subgrupo

Para garantizar que el modelo no introduzca sesgos contra poblaciones específicas, auditamos la tasa de acierto de deserción (*Recall*) desglosada por subgrupos demográficos e institucionales (Tabla 3).

Hallazgo de Equidad: La variación del Recall entre subgrupos se mantiene por debajo de 4 puntos porcentuales en todas las dimensiones evaluadas (91,97 % en hombres vs. 92,25 % en mujeres; 93,38 % en zonas rurales vs. 91,84 % en urbanas). Esto certifica

Tabla 3: Auditoría de Equidad (Fairness): Desglose del Recall de deserción por subgrupo

Variable de Control	Subgrupo Poblacional	Desertores en Test	Recall (Desertor)
`sexo`	Hombre	386	91.97 %
`sexo`	Mujer	387	92.25 %
`zona_residencia`	Rural	136	93.38 %
`zona_residencia`	Urbana	637	91.84 %
`sector_ies`	Oficial (Público)	330	94.24 %
`sector_ies`	Privado	443	90.52 %
`metodologia`	Presencial	575	92.70 %
`metodologia`	Virtual	88	90.91 %
`metodologia`	Distancia tradicional	110	90.00 %

que el clasificador se comporta de manera imparcial y es confiable para respaldar políticas institucionales.

10. Conclusiones y Recomendaciones Institucionales

1. **La normalización es un requisito estructural para SVM**: La disparidad de magnitudes altera directamente el cálculo de distancias del kernel RBF. La estandarización (`StandardScaler`) y las transformaciones de potencia (`PowerTransformer`) no son simples pasos accesorios, sino la clave que permite elevar el rendimiento de 0,41 a 0,8878 en F_1-Score.

2. **Interpretabilidad aplicada a la permanencia universitaria**: Al proyectar las fronteras sobre variables reales (`promedio_academico` vs. `materias_reprobadas`) y calcular la distancia funcional al hiperplano $f(x)$, demostramos que el modelo no opera como una caja negra, sino que permite identificar y priorizar a los estudiantes en margen crítico (vectores de soporte) para los comités de retención estudiantil.

3. **Focalización preventiva en los primeros semestres**: La importancia de variables por permutación ratifica que los esfuerzos institucionales de acompañamiento deben concentrarse con fuerza durante los tres primeros periodos académicos, cuando el promedio y las materias reprobadas poseen su mayor capacidad anticipatoria.

Referencias

[1] Boteju, G., Tang, L., & Scott Brown, M. (2024). *Support Vector Machine for Predicting Student Dropout Under Different Normalization Methods*. IEEE International Conference on Big Data (BigData), pp. 8633–8638. Washington, DC, USA: IEEE. https://doi.org/10.1109/BigData62323.2024.10825023

[2] Ministerio de Educación Nacional de Colombia. (2024). *SPADIES (Sistema para la Prevención de la Deserción en las Instituciones de Educación Superior: Cambio Metodológico SPADIES 3.0)*. Recuperado de https://www.mineducacion.gov.co/sistemasdeinformacion/1783/articles-415244_cambio_metodologico_spadies_3.pdf

[3] Peña Pico, C., Sánchez Prieto, K., Gómez Vigoya, J., & Porras Ortiz, E. (s.f.). *Sistema de Alerta Temprana de Deserción Estudiantil en la Educación Superior (SAT-DE)*. Repositorio de GitHub. https://github.com/KevinSSP/MIAD---Sistema-de-Alerta-Temprana-de-Desercion-en-la-Educacion-Superior